KERAAL 데이터 파이프라인 설계

참가자 독립 재활 운동 오류 분류 · 2026-10-02 작성 · 실제 배포 파일(1A, 2A 전체와 Group 3 파일명) 집계 기준

요약. 파이프라인을 7단계로 나누고, 각 단계가 파일을 남겨 다음 단계가 그 파일만 읽게 한다. 단계마다 통과 조건(숫자)을 두어 틀리면 그 자리에서 드러나게 한다. 테스트셋에서 표본이 충분한 오류 클래스는 9개 중 3개 뿐이므로, 주 평가는 ELK 이진 분류와 CTK 3-class로 잡는다.

1. 데이터 현황 (실제 파일 기준)

그룹	대상	참가자	녹화 수	라벨	용도
3	건강인, 오류 연기	3명 (P1–P3)	540	파일명에 C / E1–E3 + B1–B3	학습
1A	환자, 로봇 코칭	6명 (R1–R6)	250	주석자 A, B 각각 .anvil	테스트
2A	건강인, 로봇 코칭	S1–S6 (2개 장소)	51	주석자 A, B 각각 .anvil	테스트
1B / 2B	환자 / 건강인	12명 / 6명	1,631 / 151	없음	사용 안 함

- Group 3는 540 = 참가자 3 × 운동 3 × 라벨 12종 × 5회 반복이고, 운동별로 Correct / E1 / E2 / E3가 각 45개로 균형 잡혀 있다.
- 1A 녹화 수는 문서(논문, GitHub)에 249개로 적혀 있으나 실제 배포본은 250개다. 주석과 Kinect 파일은 빠짐없이 1:1로 매칭된다.
- Kinect 파일은 프레임당 175열(관절 25개 × 위치 3 + 쿼터니언 4)이고, 1A·2A에 전부 0인 프레임은 없다.

테스트셋(1A+2A) 클래스 개수

운동	주석자	Correct	E1	E2	E3	다수 클래스 비율	제외
RTK (몸통 회전)	A	73	4	6	0	88.0%	18
RTK (몸통 회전)	B	58	5	27	0	64.4%	11
ELK (옆구리 스트레칭)	A	36	0	43	0	54.4%	13
ELK (옆구리 스트레칭)	B	17	0	60	0	77.9%	15
CTK (얼굴 가리기)	A	61	26	1	17	58.1%	3
CTK (얼굴 가리기)	B	63	32	4	6	60.0%	3

제외 = Incomplete, Motionless, Other. 주석자 간 일치율은 1A에서 72% (κ는 약 0.60, 직접 계산).

2. 전체 흐름

#	단계	입력 → 출력	통과 조건
1	수집	tar.xz → raw/ (Kinect + 주석만)	2A 51개, 1A 250개, G3 540개
2	인덱스	파일명 + .anvil → master_index.csv	파싱 실패 0건, 주석↔Kinect 1:1
3	라벨	인덱스 → label_A, label_B, label_consensus	위 클래스 표와 일치
4	전처리	Kinect txt → (T, 25, 3) 정규화 배열	전부 0인 프레임 0개, 175열
5	Feature	정규화 배열 → 표현별 .npz 캐시	표현마다 shape·NaN 검사
6	분할	인덱스 → splits.json	train/test 참가자 교집합 0
7	학습·평가	캐시 + 분할 → results.csv, confusion matrix	다수 클래스 기준선이 표와 일치

3. 단계별 설계

단계 1. 수집

- 용량 대부분이 영상이므로 스트리밍으로 받아 Kinect와 주석만 남긴다. 2A와 1A는 이 방식으로 검증했다.
- Group 3는 8.7 GB를 전부 흘려야 하므로 한 번만 받고, B1–B3 의미 확인용 영상 몇 개만 따로 꺼낸다.
- 원본 tar의 크기와 받은 날짜를 기록한다. 데이터는 CC BY-NC-SA이므로 GitHub에 올리지 않는다.

```
curl -sL https://keraal.enstb.org/data/group2A.tar.xz \
  | tar -xJ --exclude='*videos*' --exclude='*openpose*' --exclude='*blazepose*'
```

단계 2. 인덱스 (master_index.csv)

- 녹화 하나가 한 행. 열: group, exercise, participant, site, trial, rec_id, kinect_path, n_frames와 주석자별 evaluation, error, severity, bodypart.
- 주석은 annotatorA/ (UTF-16)와 annotatorB/ (UTF-8) 두 폴더를 모두 읽고, 인코딩은 BOM으로 판별한다. 확장자는 .anvil이다.
- 참가자 키는 group + participant + site로 만든다. 2A의 S1이 Brest와 Roscoff 양쪽에 나오는데 같은 사람인지 알 수 없기 때문이다.

그룹	실제 파일명 예시	토큰
1A / 2A Kinect	G1A-Kinect-CTK-R1-Brest-022.txt	그룹-모달리티-운동-참가자-장소-녹화ID
1A / 2A 주석	G1A-CTK-R1-Brest-022.anvil	그룹-운동-참가자-장소-녹화ID
3	G3-Kinect-CTK-P1T1-Unknown-E1B1-0.txt	그룹-모달리티-운동-참가자+trial-Unknown-라벨-반복

단계 3. 라벨

- 기본 규칙: Incorrect이고 오류가 E1–E3이면 그 오류, Correct면 Correct. Incomplete / Motionless / Other는 제외 표시만 하고 행은 남긴다.
- 주석자 A, 주석자 B, 둘이 일치한 표본만 쓰는 consensus 세 가지 라벨 열을 만든다.
- CTK는 E1과 E3를 합친 변형 열도 둔다. 두 논문에서 설명이 같고("Arms are not raised enough"), A가 E3로 본 17건 중 B가 동의한 것은 6건이다.
- Group 3는 C / E1–E3와 B1–B3를 따로 열로 분리한다.

단계 4. 전처리

- 175열에서 관절별 위치 3개만 꺼내 (T, 25, 3)으로 만든다. 쿼터니언 일부는 0이라 기본 입력에서 제외한다.
- 순서: SpineBase 기준 중심 이동 → 수직축 회전으로 어깨선 정렬 → 몸통 길이로 스케일 정규화 → 가벼운 평활화 → 고정 길이로 리샘플링.
- "raw"와 "정규화한 raw"를 둘 다 저장한다. 그래야 정규화 효과와 feature 효과를 분리할 수 있다.

단계 5. Feature (표현 사다리)

표현	내용	직전 단계 대비 바뀌는 것
R0	raw 좌표	—
R1	정규화 좌표	위치·방향·체격 정규화
R2	관절각	좌표 → 각도
R3	관절각 + 속도	시간 변화량 추가
R4	관절각 + 속도 + 좌우 대칭	좌우 차이 추가
R-err	오류 정의에 맞춘 소수 feature	어깨 거상각, 어깨선-골반선 회전각, 척추 기울기, 팔꿈치 굴곡각, 손목 간 거리

- fps를 확정하지 못했으므로 속도는 리샘플링 후 "정규화 시간 기준"으로 계산하고 그렇게 명시한다.
- 좌우 반전은 augmentation으로만 쓴다. 한 녹화에 왼쪽·오른쪽 동작이 모두 들어 있다.
- 오류별 feature는 라벨링 가이드와 Group 3만 보고 설계한 뒤, 테스트셋을 보기 전에 고정한다.

단계 6. 분할 (splits.json)

프로토콜	학습	테스트	측정하는 것
P1 (주)	Group 3	1A, 2A (따로 보고)	sim-to-real 전이
P2	Group 3 중 2명	Group 3 중 1명 (3-fold)	사람이 바뀌는 효과
P3	같은 데이터	random vs 참가자 단위	누수로 인한 성능 부풀림

정규화 통계는 반드시 train에서만 계산한다. seed는 고정해 파일로 남긴다.

단계 7. 학습·평가

- 모델 순서: 다수 클래스 → 요약 통계 + Random Forest → LSTM → TCN. 설정 파일 하나로 표현·모델·분할·seed를 바꾼다.
- 주 결과: ELK 이진(Correct 36 / E2 43), CTK 3-class(Correct 61 / E1 26 / E3 17). RTK는 참고용(E1 4, E2 6, E3 0).
- 지표: Macro-F1(테스트에 존재하는 클래스만), balanced accuracy, 클래스별 recall, confusion matrix.
- 불확실성: seed 5개 평균 ± 표준편차와 함께 참가자 단위 bootstrap 신뢰구간. 1A에서 오류가 특정 환자에 몰려 있다(E3 17건 중 10건이 R2).
- 주석자 A, B 양쪽 라벨로 결과를 낸다. 어느 쪽을 쓰느냐로 RTK의 다수 클래스 기준선이 88%에서 64%로 바뀐다.
- 심각도(SmallError / LargeError)별 recall을 따로 표로 낸다.

4. 필수 점검: trial과 오류의 교란

Group 3는 trial과 오류가 묶여 있다. T1에는 Correct와 E1만, T2에는 Correct와 E2만, T3에는 Correct와 E3만 있다. 모델이 오류가 아니라 촬영 세션의 차이(서 있는 위치 등)를 배울 수 있다.

점검 방법. 전처리 후 Correct 표본만으로 trial(T1/T2/T3)을 맞히는 분류기를 돌린다. 우연 수준(33%)보다 뚜렷이 높으면 정규화를 더 강하게 한다.

5. 폴더 구조

```
keraal/
  raw/        원본 (git 제외)
  data/       master_index.csv, splits.json, features/*.npz
  src/        index.py, labels.py, preprocess.py, features.py,
              splits.py, train.py, evaluate.py
  configs/    실험 설정
  results/    results.csv, 그림
```

6. 구현 순서

순서	작업	끝났다는 기준
1	단계 2–3: 인덱스와 라벨	master_index.csv의 클래스 개수가 1절 표와 일치
2	단계 4와 trial 교란 점검	Correct 표본의 trial 분류 정확도 보고
3	단계 6과 다수 클래스·RF 기준선	splits.json 고정, 기준선 결과표
4	단계 5: 표현 사다리 R0–R4	표현별 캐시 생성
5	단계 7: LSTM, TCN	seed 5개 결과와 신뢰구간

7. 아직 확인되지 않은 것

- **Group 3의 B1–B3 의미.** 문서에 없다. 영상으로 확인해야 한다.
- **fps.** 프레임 수를 주석의 종료 시각으로 나눈 값이 15~922로 흩어져 있어, 주석의 시간 값은 초 단위로 믿을 수 없다. 영상 길이로 따로 확인해야 한다.
- **Group 3 골격 데이터.** 파일명 540개는 모두 확인했으나 골격 파일은 샘플 6개만 열어 봤다.
- **2A의 S1.** Brest와 Roscoff의 S1이 같은 사람인지 알 수 없다.

8. 다운로드 링크

파일	크기	링크
샘플	118 MB	https://keraal.enstb.org/data/keraal_sample_2022.zip
group2A	354 MB	https://keraal.enstb.org/data/group2A.tar.xz
group1A	1.47 GB	https://keraal.enstb.org/data/group1A.tar.xz
group3	8.7 GB	https://keraal.enstb.org/data/group3.tar.xz
형식 설명	5 KB	https://keraal.enstb.org/data/readme_files_format.txt
공식 페이지	—	https://keraal.enstb.org/KeraalDataset.html